

IA : concepts fondamentaux

- ✓ AI / ML / DL
- ✓ Différents types d'apprentissage
- ✓ Classification vs Régression
- ✓ Les données
 - ✓ Représentation
 - ✓ Prétraitement
 - ✓ Entraînement/test
- ✓ Evaluation
- ✓ Principe général de l'apprentissage

Françoise Bouvet
francoise.bouvet@ijclab.in2p3.fr

**Intelligence artificielle :
Simulation du comportement du cerveau**

**Machine Learning
Apprentissage Automatique :
Approche statistique de l'IA**

Clustering

Decision Tree

SVM

Régression

**Deep Learning
Apprentissage Profond
~ Réseaux de Neurones**

ANN

CNN

RNN

SVM : Support Vector Machine
ANN : Artificial Neural Network
CNN : Convolution NN
RNN : Recurrent NN



Identifier le problème

Types d'apprentissage (1)


Apprentissage **supervisé**

Les données sont **étiquetées**, l'algorithme apprend à **prédire**

- Classification
- Segmentation
- Génération de texte, d'images, ...



Fleur




Animal

Apprentissage **non supervisé**

Les données ne sont **pas étiquetées**, l'algorithme apprend leur **structure** inhérente

- Détection d'anomalies
- Clustering



Types d'apprentissage (2)

Apprentissage **par renforcement**

Basé sur un cycle **expérience / récompense** ; améliore les performances à chaque itération

- Robot
- Réseaux sociaux (like, temps passé)
- Jeux vidéo

Apprentissage **semi-supervisé**

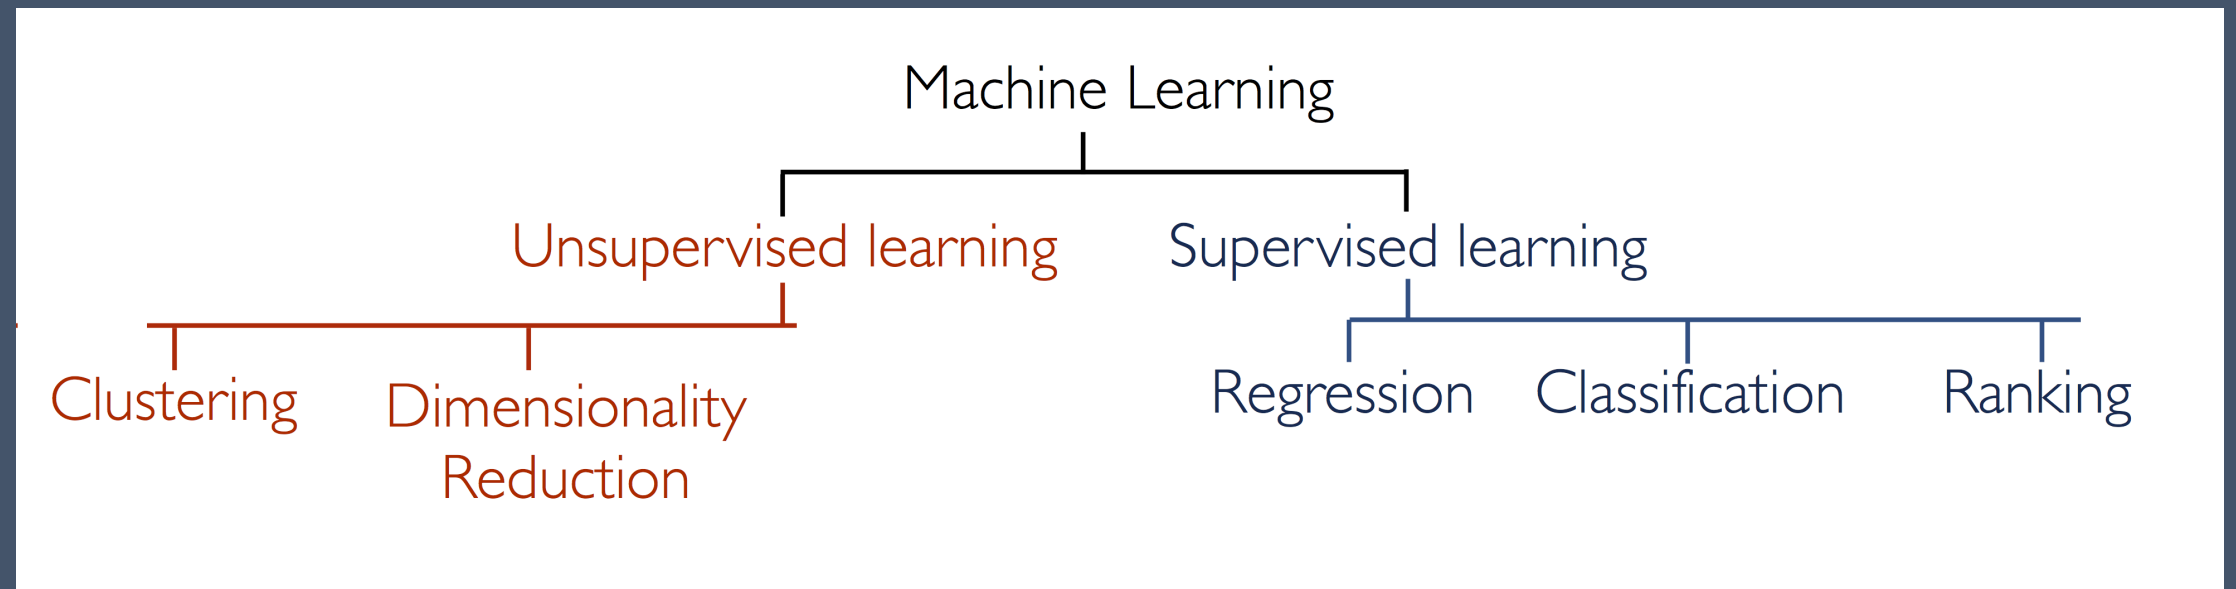
Seules certaines données sont étiquetées

Idée : Utiliser les données non annotées pour compléter l'apprentissage supervisé (coût de l'annotation)

Co-apprentissage

- Etiquetage (texte, image)


Apprentissage supervisé / non supervisé



Classification / Régression


Régression

La valeur en sortie est **continue** (nombre réel)



Classification

La valeur en sortie est **discrète** (catégorie)



Il est **essentiel** d'identifier le problème car de nombreux algorithmes fonctionnent dans les deux cas mais avec des paramètres différents

Classification

Binaire (2 classes)

- Oui/ non
- Bénin/malin
- ...



Régression logistique :
classification à 2 classes

Multi-classes

- Objets
- Pays
- Pathologie
- ...

Labels ordonnés (*ranking*)

- Taille d'en vêtement
- Classe d'âge
- ...



Gérer les données

Prétraitement des données : test / apprentissage

Le modèle ne doit jamais être évalué sur les données utilisées pour le construire.

Utiliser les mêmes données pour entraîner et pour tester un modèle est une **erreur méthodologique**.

- L'ensemble de données est divisé en 2 sous-ensembles.



Sur-apprentissage

Prétraitement des données : encodage/normalisation

Le prétraitement des données est **essentiel** pour beaucoup de modèles.

Données catégorielles

- Encodage ordinal
 - Attribution d'une valeur entière à chaque classe
- Encodage « One-hot »
 - la catégorie est représentée par un vecteur de 0, sauf une valeur à 1.

Données continues

- Centrage et normalisation
- Discretisation

Ensemble de données : principaux défis

1. Quantité insuffisante de données
2. Données non représentatives (biais d'échantillonnage)
3. Données de piètre qualité
 - Bruitées
 - Incomplètes
4. Données inutiles ou non corrélées avec le problème
5. Classes non équilibrées (imbalanced classes)

➤ Des données inadaptées peuvent conduire à du **sur-** ou **sous-** entraînement

Evaluer le modèle

Evaluation

Définir un critère d'évaluation du modèle est essentiel

- Après l'apprentissage : évaluation
- Pendant l'apprentissage : minimisation de l'erreur

➤ Le critère dépend de la classe de problème

- Régression
- Classification

➤ Le critère peut être modifié pour s'adapter au problème à traiter

- Classes non balancées (imbalanced classes)
- Information a priori

Evaluation - Régression

Mean Squarred Error (MSE)

- Pénalise les grandes valeurs -> sensible aux valeurs aberrantes (outliers)
- Facilement différentiable

$$\text{MSE}(y, \hat{y}) = \frac{1}{N_{\text{samples}}} \sum_{i=0}^{N_{\text{samples}}-1} (y_i - \hat{y}_i)^2$$

Score R^2

- Utilisé pour comparer différents modèles
- Aucune information sur l'erreur moyenne du modèle

$$R^2(y, \hat{y}) = 1 - \frac{\sum_{i=0}^{N_{\text{samples}}-1} (y_i - \hat{y}_i)^2}{\sum_{i=0}^{N_{\text{samples}}-1} (y_i - \bar{y})^2}$$

Evaluation – Classification binaire (1)

Précision (accuracy)

$$\text{accuracy}(y, \hat{y}) = \frac{1}{N_{\text{samples}}} \sum_{i=0}^{N_{\text{samples}}-1} 1(y_i = \hat{y}_i) = \frac{\text{TP} + \text{TN}}{\text{TP} + \text{FP} + \text{TP} + \text{TN}}$$

actual negative	True Negative	False Positive
	False Negative	True Positive
		predicted negative predicted positive

		y_pred_1		y_pred_2		y_pred_3	
True label	N	90	0	80	10	85	5
	P	10	0	0	10	5	5
		N	P	N	P	N	P
		Predicted label		Predicted label		Predicted label	

Accuracy=0.9 dans tous les cas

Evaluation – Classification binaire (2)

Precision

Capacité du modèle à ne pas prévoir négativement des valeurs positives

$$\text{precision} = \frac{TP}{TP + FP}$$

Recall

Capacité du modèle à prédire les valeurs positives

$$\text{recall} = \frac{TP}{TP + FN}$$

F1-score


Moyenne harmonique entre la précision et le recall

$$F = 2 \frac{\text{precision} \times \text{recall}}{\text{precision} + \text{recall}}$$

Evaluation – Classification binaire (3)

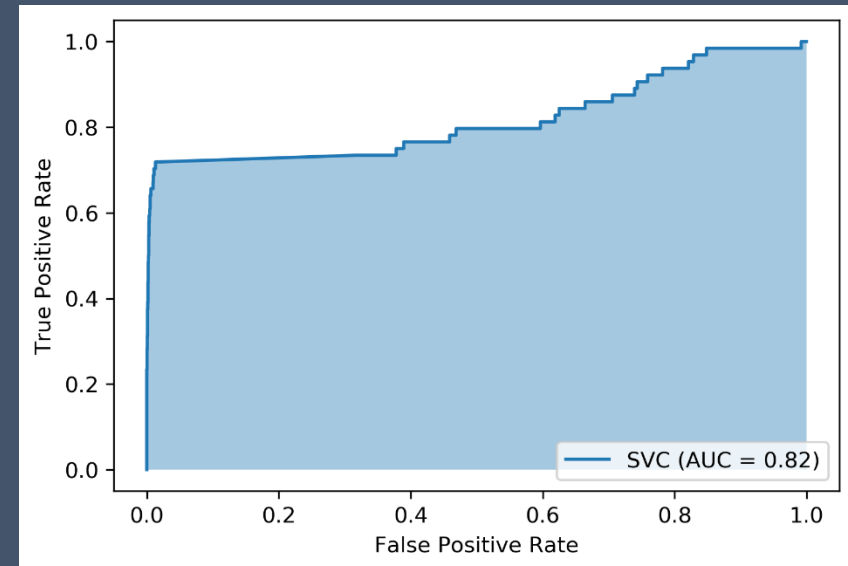
ROC Curve (Receiver Operating Characteristic)

Montre les performances du modèle en fonction du seuil de classification



AUC (Area Under the Curve)

Sorte de mesure de la séparabilité du modèle.

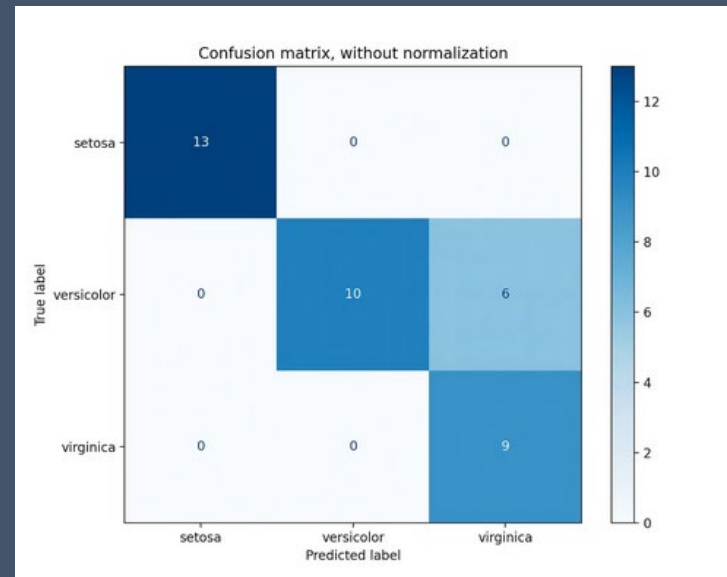


Evaluation – Classification multi-classe


Métriques binaires

Les métriques utilisées en classification binaire peuvent être calculées classe par classe.

Matrice de confusion
Résumé des prédictions.



Classification d'iris : matrice de confusion



Classification d'iris : matrice de confusion normalisée

Principe général de l'apprentissage

